Pemetaan Sinyal EEG *Imagined Speech* ke Vektor Makna sebagai Antarmuka *Prompting Language Model*

Proposal Tugas Akhir

Oleh

Leonard Arif Sutiono
18223120



PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG

Oktober 2026

LEMBAR PENGESAHAN

Pemetaan Sinyal EEG *Imagined Speech* ke Vektor Makna sebagai Antarmuka *Prompting Language Model*

Proposal Tugas Akhir

Oleh

Leonard Arif Sutiono
18223120

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 27 Oktober 2026

Pembimbing 1	Pembimbing 2
Dessi Puji Lestari, S.T, M.Eng., Ph.D.	Nur Ahmadi, S.T., M.Eng., Ph.D.
NIP. 197912012012122005	NIP. 123110012

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Proposal Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenar-benarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan Proposal Tugas Akhir.
3. Isi proposal ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa dokumen laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 27 Oktober 2026

John Doe
NIM: 18299000

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan Proposal Tugas Akhir ini, saya telah menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu. Berikut adalah rincian penggunaan AI dalam penulisan tesis ini.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Memeriksa ejaan dan tata bahasa	Grammarly	Tinggi	Semua bab
2	Pembuatan teks	Microsoft Copilot	Sedang	Bab II dan Subbab III.2 hal. 34
3	Pembuatan grafik, gambar, atau ilustrasi	Tidak ada	Tidak ada	Tidak ada
4	Pencarian informasi atau referensi	…	…	…
5	Menjelaskan definisi, konsep, gambar, tabel, atau topik tertentu	…	…	…
6	Penyusunan kode program	…	…	…
7	Penyusunan formula atau perhitungan matematis	…	…	…
8	Analisis data	…	…	…
9	Penyusunan kesimpulan atau rekomendasi	…	…	…
10	Lainnya (jelaskan)	…	…	…

Bandung, 27 Oktober 2026

John Doe
NIM: 18299000

DAFTAR ISI

LEMBAR PENGESAHAN iii
PERNYATAAN ORISINALITAS v
PERNYATAAN PENGGUNAAN AI vii
DAFTAR ISI ix
DAFTAR GAMBAR xi
DAFTAR TABEL xiii
DAFTAR PERSAMAAN xv
DAFTAR ALGORITMA xvii
DAFTAR KODE PROGRAM xix
DAFTAR SINGKATAN xxi
DAFTAR SIMBOL xxiii

BAB I PENDAHULUAN 1
I.1 Latar Belakang 1
I.2 Rumusan Masalah 3
I.3 Tujuan 4
I.4 Ruang Lingkup, Asumsi, dan Batasan Masalah 4
I.5 Hipotesis 5
I.6 Metodologi 6
I.7 Sistematika Penulisan 8

BAB II STUDI LITERATUR 11
II.1 *Brain-Computer Interface* (BCI) 11
II.1.1 Alur Kerja BCI 11
II.1.1.1 Perekaman Sinyal Otak 12
II.1.1.2 Pemrosesan Sinyal 14
II.1.1.3 Tantangan BCI 14
II.1.1.4 Aplikasi BCI 15
II.1.2 *Imagined Speech* 15
II.2 EEG 16
II.2.1 Cara Kerja EEG 16
II.2.2 *Dataset* EEG *Imagined Speech* 17
II.3 Penyeragaman Sinyal Antar Subjek dengan RCT 17
II.4 Vektor Makna dan Pemetaan EEG ke Vektor 19
II.4.1 Vektor Makna 19
II.4.2 Model *Sentence Embedding* 20
II.4.3 Pemetaan Sinyal Otak ke Vektor Makna 21
II.5 *Sparse Autoencoder* (SAE) 22
II.6 *Large Language Model* (LLM) 23
II.7 *Soft Prompt* 23
II.8 *Adapter* 24
II.9 *Low-Rank Adaptation* (LoRA) 25
II.10 Metrik Evaluasi dan Uji Statistik 25
II.11 Penelitian Terkait 26

BAB III ANALISIS MASALAH **29**
III.1 Analisis Kondisi Saat Ini 29
III.2 Analisis Kebutuhan 30
III.2.1 Identifikasi Masalah Pengguna 30
III.2.2 Kebutuhan Fungsional 31
III.2.3 Kebutuhan Nonfungsional 32
III.3 Analisis Pemilihan Solusi 32
III.3.1 Alternatif Solusi 32
III.3.2 Analisis Penentuan Solusi 33

DAFTAR PUSTAKA **35**

Lampiran A *SOURCE CODE* **39**
A.1 Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik . . . 39
A.2 Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak 40

DAFTAR GAMBAR

II.1 Alur kerja BCI, mulai dari perekaman data, pemrosesan sinyal, hingga aplikasi, beserta tantangan yang menjadi fokus penelitian ini (diadaptasi dari Jeong dkk., 2022, lisensi CC BY) 12

II.2 Sistem internasional 10-20 dilihat dari kiri (A) dan atas kepala (B) (sumber: Malmivuo & Plonsey, 1995) 16

II.3 Alur MEKT: penyelarasan pusat data pada *manifold* Riemann, pemetaan ke *tangent space*, lalu pembelajaran subruang (sumber: Zhang & Wu, 2020) 18

II.4 Ilustrasi ruang semantik dua dimensi, dengan kata-kata yang maknanya berdekatan membentuk kelompok (sumber: Pereira dkk., 2018) 20

II.5 Arsitektur SBERT saat menghitung kemiripan dua kalimat (diadaptasi dari Reimers & Gurevych, 2019) 21

II.6 Ilustrasi struktur *sparse autoencoder*, dengan unit yang aktif ditandai warna oranye 23

II.7 Perbandingan *prompt* biasa dan dua bentuk *soft prompt* (diadaptasi dari Lester dkk., 2021; Mokady dkk., 2021) 24

II.8 Reparameterisasi LoRA: bobot *pretrained* dibekukan dan hanya matriks A dan B yang dilatih (sumber: Hu dkk., 2021) 25

DAFTAR TABEL

II.1 Perbandingan metode perekaman sinyal otak untuk BCI 13
II.2 Ringkasan penelitian terkait 28

III.1 Identifikasi masalah pengguna 31
III.2 Kebutuhan fungsional 32
III.3 Kebutuhan nonfungsional 32
III.4 Penyaringan alternatif solusi 34

DAFTAR PERSAMAAN

II.1 Matriks kovarians spasial 17
II.2 Rata-rata Riemann 18
II.3 Pemusatan matriks kovarians 18
II.4 *Cosine similarity* 19
II.5 Pelatihan model pemetaan sinyal ke vektor makna 21
II.6 Fungsi galat *sparse autoencoder* 22
II.7 Reparameterisasi *low-rank* pada LoRA 25
II.8 *Balanced accuracy* 26

DAFTAR ALGORITMA

DAFTAR *LISTING*

A.1 Binary search code 39

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
AAC	*Augmentative and Alternative Communication*	32
AI	*Artificial Intelligence*	2
ALS	*Amyotrophic Lateral Sclerosis*	1
ASHA	*American Speech-Language-Hearing Association*	1
BCI	*Brain-Computer Interface*	1
BERT	*Bidirectional Encoder Representations from Transformers*	20
CLIP	*Contrastive Language-Image Pre-training*	19
ECoG	Elektrokortikografi	1
EEG	Elektroensefalografi	1
ERP	*Event-Related Potential*	15
fMRI	*Functional Magnetic Resonance Imaging*	1
fNIRS	*Functional Near-Infrared Spectroscopy*	12
GPT	*Generative Pre-trained Transformer*	24
GPU	*Graphics Processing Unit*	25
ICLR	*International Conference on Learning Representations*	26
LLM	*Large Language Model*	2
LoRA	*Low-Rank Adaptation*	8
MEG	Magnetoensefalografi	1
MEKT	*Manifold Embedded Knowledge Transfer*	18
PEFT	*Parameter-Efficient Fine-Tuning*	8
RCT	*Riemannian Centering Transformation*	3
Riskesdas	Riset Kesehatan Dasar	1
SAE	*Sparse Autoencoder*	7
SBERT	*Sentence-BERT*	20
SNR	*Signal-to-Noise Ratio*	16

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
α	Kekuatan penalti agar sedikit angka yang aktif pada *sparse autoencoder*	22
δ_R	Jarak Riemann antara dua matriks kovarians	18
θ	Parameter model pemetaan sinyal ke vektor makna	21
$\hat{\theta}$	Parameter terbaik hasil pelatihan	21
ΔW	Perubahan bobot LLM pada LoRA	25
$\sim$	Sekitar (nilai perkiraan)	13
$\sum$	Operator penjumlahan	18
$\arg\min$	Argumen yang meminimalkan fungsi	18
$\succ 0$	Matriks bersifat positif definit	18
$\top$	Transpos matriks	17
$\cdot$	Hasil kali titik (*dot product*) dua vektor	19
$\|\cdot\|$, $\|\cdot\|_2$	Norma vektor (panjang vektor)	19
$\|\cdot\|_1$	Norma ℓ_1, yaitu jumlah nilai mutlak setiap angka vektor	22
$\in$	Anggota himpunan	25
$\mathbb{R}$	Himpunan bilangan real	25
$\ll$	Jauh lebih kecil daripada	25
$\cos(\mathbf{a}, \mathbf{b})$	*Cosine similarity* antara vektor **a** dan **b**	19
N	Jumlah *channel* EEG	17
T	Jumlah titik waktu dalam satu percobaan	17
X_i	Sinyal EEG percobaan ke-i berukuran $N \times T$	17
C_i	Matriks kovarians spasial percobaan ke-i berukuran $N \times N$	17
$\bar{C}$	Rata-rata Riemann dari matriks kovarians satu subjek	18

$\tilde{C}_i$	Matriks kovarians percobaan ke-i setelah dipusatkan (RCT)	18
M	Jumlah percobaan	18
a, **b**	Dua vektor yang dibandingkan kedekatannya	19
$\mathbf{x}_i$	Fitur sinyal pada percobaan ke-i	21
$\mathbf{y}_i$	Vektor makna target pada percobaan ke-i	21
f_θ	Model pemetaan dengan parameter θ	21
$\mathbf{x}$	Vektor masukan *sparse autoencoder*	22
$\hat{\mathbf{x}}$	Hasil rekonstruksi vektor masukan	22
$\mathbf{f}$	Angka-angka pada lapisan tengah *sparse autoencoder*	22
$\mathcal{L}$	Fungsi galat *sparse autoencoder*	22
W	Bobot LLM setelah disesuaikan dengan LoRA	25
W_0	Bobot LLM yang dibekukan	25
B, A	Dua matriks kecil yang dilatih pada LoRA	25
d, k	Ukuran baris dan kolom bobot W_0	25
r	Peringkat (*rank*) matriks B dan A	25
C	Jumlah kata pada perhitungan *balanced accuracy* (pada arg min di Persamaan II.2, matriks kandidat rata-rata)	25
TP_i	Jumlah percobaan kata ke-i yang ditebak benar	25
FN_i	Jumlah percobaan kata ke-i yang ditebak sebagai kata lain	25
B-Acc	*Balanced accuracy*	26
p	Nilai p (nilai probabilitas uji statistik)	26

BAB I

PENDAHULUAN

I.1 Latar Belakang

Kemampuan berkomunikasi dapat hilang akibat berbagai gangguan saraf, salah satunya afasia, yaitu gangguan berbahasa akibat kerusakan jaringan bahasa di otak yang dapat disebabkan oleh stroke, cedera otak traumatis, tumor otak, operasi otak, infeksi otak, maupun penyakit saraf degeneratif seperti demensia (ASHA, t.t.). Di antara penyebab tersebut, stroke merupakan penyebab yang paling umum (ASHA, t.t.). Secara nasional, prevalensi stroke di Indonesia tahun 2018 berdasarkan diagnosis dokter pada penduduk berumur 15 tahun ke atas adalah 10,9 per mil, atau diperkirakan sekitar 2.120.362 orang (Riskesdas, 2018). Setelah stroke, hingga 40% penderita mengalami afasia, dan pada sekitar 60% penyintas kondisi ini menjadi menetap (Cochrane dkk., 2025).

Selain afasia, gangguan saraf dan otot berat seperti *amyotrophic lateral sclerosis* (ALS) dan stroke batang otak juga membuat penderitanya kesulitan berkomunikasi (Wolpaw dkk., 2002). Penderita kondisi-kondisi ini bisa saja tahu apa yang ingin disampaikan, tetapi kesulitan mengeluarkannya lewat ucapan maupun tulisan. Kondisi ini mendorong berkembangnya antarmuka otak-komputer (*brain-computer interface* atau BCI), yaitu jalur baru untuk mengirim pesan dan perintah dari otak ke dunia luar tanpa melalui otot (Wolpaw dkk., 2002). BCI bekerja dengan mengubah sinyal otak menjadi keluaran yang menyampaikan maksud penggunanya (Wolpaw & McFarland, 2004).

Sinyal otak untuk BCI dapat direkam dengan beberapa cara. Elektrokortikografi (ECoG) memerlukan operasi untuk menempatkan elektroda di permukaan otak, sedangkan fMRI dan MEG menggunakan alat berukuran besar yang tidak dapat dipindahkan (Nicolas-Alonso & Gomez-Gil, 2012). Elektroensefalografi (EEG) merekam aktivitas listrik otak melalui elektroda di kulit kepala, sehingga tidak memerlukan operasi, dapat dibawa, dan mampu menangkap perubahan sinyal dalam hitungan sekitar 0,05 detik (Nicolas-Alonso & Gomez-Gil, 2012). Dibandingkan

alat perekam otak lainnya, EEG dinilai memberikan kompromi terbaik antara ketelitian, kepraktisan, dan biaya (Frey dkk., 2014), sehingga paling memungkinkan untuk dipakai sehari-hari di samping pasien.

Salah satu pemanfaatan EEG dalam BCI adalah *imagined speech*, yaitu membaca sinyal otak saat seseorang membayangkan mengucapkan sebuah kata dalam hati tanpa menggerakkan mulut. Sinyal ini dapat dimanfaatkan sebagai jalur komunikasi baru bagi orang yang tidak mampu berbicara akibat disabilitas motorik atau penyakit saraf (López-Bernal dkk., 2022). Pendekatan yang paling umum digunakan adalah klasifikasi, yaitu model dilatih untuk memilih satu kata dari sekumpulan kecil kata yang sudah ditentukan sebelumnya (López-Bernal dkk., 2022).

Di sisi lain, penelitian *decoding* sinyal otak mulai bergeser dari menebak kata menjadi menangkap makna. Tang dkk. (2023) memperkenalkan *decoder* yang merekonstruksi bahasa dari representasi makna di otak, dan mampu menghasilkan rangkaian kata yang maknanya sesuai dengan ucapan yang dibayangkan seseorang. Pendekatan ini memanfaatkan model bahasa yang merepresentasikan makna kata sebagai deretan angka (vektor), sehingga kata-kata yang maknanya berdekatan juga memiliki vektor yang berdekatan. Representasi makna dalam bentuk vektor juga dapat dibaca langsung oleh model bahasa besar (*large language model* atau LLM), yaitu model AI yang mampu memahami dan menyusun kalimat. Lester dkk. (2021) menunjukkan bahwa LLM dapat diarahkan dengan memberikan deretan vektor sebagai masukan, yang disebut *soft prompt*, tanpa harus menuliskannya dalam bentuk kalimat. Dengan cara ini, LLM dapat menjalankan tugas tertentu dengan performa yang mendekati model yang dilatih ulang secara penuh, padahal model bahasanya sendiri tidak diubah.

Untuk sinyal EEG dari orang yang berbeda, telah dikembangkan teknik penyeragaman sinyal berbasis geometri Riemann, yaitu menggeser pola sinyal setiap orang ke titik acuan yang sama sehingga sinyal dari orang yang berbeda lebih mudah dibandingkan. Caranya, pola rata-rata sinyal setiap orang dihitung terlebih dahulu, lalu setiap rekaman orang tersebut disesuaikan terhadap pola rata-ratanya sendiri. Zanini dkk. (2018) menunjukkan bahwa teknik ini membantu model BCI tetap bekerja pada orang yang berbeda.

Meski demikian, *imagined speech* berbasis EEG masih menghadapi sejumlah kendala dari sisi sinyal. Sinyal EEG saat *imagined speech* memiliki rasio sinyal terhadap gangguan yang rendah, sehingga bagian sinyal yang penting sulit dibedakan dari aktivitas otot, gerakan mata, atau kedipan (López-Bernal dkk., 2022). Akibatnya,

teknik non-invasif lebih sulit melampaui ambang akurasi sekitar 70% yang dianggap layak untuk penerapan nyata dibandingkan teknik invasif (López-Bernal dkk., 2022). Sinyalnya juga bervariasi tinggi antar orang, sementara kosakata yang digunakan masih kecil dan himpunan data yang tersedia terbatas ukurannya (Duhair dkk., 2026). Teknik penyeragaman berbasis geometri Riemann yang dapat membantu mengatasi variasi ini pun diuji pada BCI gerakan yang dibayangkan (*motor imagery*) dan jenis BCI lainnya, belum pada *imagined speech* (Zanini dkk., 2018).

Kendala lainnya berasal dari pendekatan yang digunakan. Tang dkk. (2023) mencatat bahwa *decoder* non-invasif sebelumnya hanya mampu mengenali stimulus dari sekumpulan kecil kata atau frasa, dan pada *imagined speech* berbasis EEG pendekatannya masih didominasi oleh klasifikasi ke label kata, belum memanfaatkan representasi makna. Pendekatan klasifikasi juga hanya menilai keberhasilan sistem sebagai benar atau salah, sehingga tebakan yang maknanya dekat dengan kata yang dimaksud dihitung sama salahnya dengan tebakan yang melenceng jauh. Selain itu, keluaran sistem berhenti pada satu label kata, bukan teks yang langsung dapat dipahami orang di sekitar pengguna.

Permasalahan pada studi sebelumnya dapat diatasi dengan memetakan sinyal EEG *imagined speech* ke vektor makna, bukan ke satu label kata. Sebelum dipetakan, sinyal EEG setiap orang terlebih dahulu diseragamkan menggunakan *Riemannian Centering Transformation* (RCT) untuk meningkatkan *robustness* model dari sisi subjek pelatihan. Dengan cara ini, hasil pemetaan dapat dinilai berdasarkan seberapa dekat maknanya dengan kata yang dimaksud, tidak lagi hanya benar atau salah. Vektor makna tersebut kemudian diberikan sebagai konteks kepada LLM, yang bertugas merangkai maksud pengguna menjadi teks utuh yang mudah dipahami. Melalui pendekatan ini, diharapkan tercipta sistem komunikasi berbasis EEG yang menghasilkan keluaran yang lebih mudah dimengerti, sehingga dapat menjadi dasar alat bantu komunikasi bagi penderita gangguan bicara seperti afasia.

I.2 Rumusan Masalah

Berdasarkan latar belakang yang sudah diuraikan, berikut merupakan rumusan masalah untuk tugas akhir ini:

1. Bagaimana sinyal EEG *imagined speech* dapat dimanfaatkan agar maksud penderita gangguan bicara dapat tersampaikan dalam bentuk teks yang dapat dipahami oleh orang di sekitarnya?
2. Bagaimana perbandingan ketepatan pengenalan kata antara pemetaan sinyal EEG *imagined speech* ke vektor makna dan pendekatan klasifikasi ke label

kata?

3. Apakah penyeragaman sinyal EEG menggunakan *Riemannian Centering Transformation* (RCT) dapat meningkatkan *robustness* model dari sisi subjek pelatihan?

I.3 Tujuan

Berdasarkan uraian latar belakang dan rumusan masalah, tujuan tugas akhir ini adalah sebagai berikut.

1. Mengembangkan sistem yang memetakan sinyal EEG *imagined speech* ke vektor makna dan merangkainya menjadi teks utuh menggunakan LLM, serta membandingkan ketepatan pengenalan katanya dengan pendekatan klasifikasi ke label kata.
2. Menganalisis pengaruh penyeragaman sinyal EEG menggunakan RCT terhadap *robustness* model dari sisi subjek pelatihan.

Adapun keberhasilan tugas akhir ini diukur melalui hal-hal berikut.

1. Sistem dapat menghasilkan teks dari sinyal EEG *imagined speech*, dan proporsi teks yang dinilai sesuai dengan kata yang dimaksud oleh penilai manusia berada di atas tingkat tebakan acak.
2. Akurasi pengenalan kata model vektor makna dan model klasifikasi pada data uji yang sama dilaporkan beserta hasil uji signifikansi perbedaannya.
3. Akurasi model dengan dan tanpa RCT pada pengujian lintas subjek dilaporkan beserta hasil uji signifikansi perbedaannya, dengan akurasi model dengan RCT berada di atas tingkat tebakan acak.

I.4 Ruang Lingkup, Asumsi, dan Batasan Masalah

Ruang lingkup tugas akhir ini adalah sebagai berikut:

1. Sinyal yang diolah adalah sinyal EEG saat seseorang membayangkan mengucapkan kata atau frasa pendek dalam hati (*imagined speech*), bukan kalimat panjang atau pikiran bebas.
2. Data yang digunakan berasal dari perekaman data EEG *imagined speech* baru, dengan jumlah kata atau frasa yang terbatas.
3. Sistem mencakup tiga bagian: penyeragaman sinyal EEG, pemetaan sinyal ke vektor makna, dan perangkaian vektor makna menjadi teks utuh oleh LLM.
4. LLM yang digunakan adalah model sumber terbuka berukuran ringan, yang menerima vektor makna sebagai masukan melalui *adapter*.
5. Evaluasi mencakup perbandingan akurasi dengan pendekatan klasifikasi, pengaruh RCT pada pengujian lintas subjek, dan penilaian kesesuaian teks oleh penilai manusia.

6. Pengujian dilakukan dalam dua skema, yaitu per orang (model dilatih dan diuji pada data orang yang sama) dan lintas subjek (model diuji pada orang yang datanya tidak digunakan saat pelatihan).

Asumsi yang digunakan dalam tugas akhir ini adalah sebagai berikut:

1. Sinyal EEG saat *imagined speech* mengandung informasi yang cukup untuk dipetakan ke makna kata yang dibayangkan.
2. Partisipan pada perekaman data benar-benar membayangkan kata yang diminta sesuai instruksi perekaman.
3. Vektor makna dari model bahasa yang sudah dilatih sebelumnya cukup mewakili makna kata yang dibayangkan.
4. Pola sinyal EEG *imagined speech* pada orang sehat cukup mewakili pola pada penderita afasia, sehingga hasil tugas akhir ini relevan sebagai dasar alat bantu komunikasi bagi mereka.

Batasan masalah dalam tugas akhir ini adalah sebagai berikut:

1. Perekaman data baru dilakukan pada orang sehat, dan tugas akhir ini tidak melibatkan pengujian langsung pada penderita afasia.
2. Pengujian lintas subjek hanya dilakukan pada partisipan yang datanya direkam dalam tugas akhir ini, dan tidak dimaksudkan untuk menghasilkan sistem yang siap dipakai langsung oleh pasien baru tanpa penyesuaian.
3. Tugas akhir ini tidak mencakup pembacaan bayangan visual, hanya kata yang diucapkan dalam hati.
4. Teks yang dihasilkan LLM menggunakan bahasa Inggris.
5. Pengujian dilakukan pada data rekaman yang sudah ada (*offline*), tidak mencakup penggunaan secara langsung saat orang sedang berpikir (*real-time*).

I.5 Hipotesis

Hipotesis dalam tugas akhir ini disusun berdasarkan premis-premis berikut:

1. Sinyal EEG saat *imagined speech* dapat dimanfaatkan sebagai jalur komunikasi bagi orang yang tidak mampu berbicara (López-Bernal dkk., 2022).
2. *Decoder* yang memetakan sinyal otak ke representasi makna mampu menghasilkan rangkaian kata yang maknanya sesuai dengan ucapan yang dibayangkan (Tang dkk., 2023).
3. Dalam representasi makna berbentuk vektor, kata-kata yang maknanya berdekatan memiliki vektor yang berdekatan, sehingga kedekatan makna dapat diukur sebagai nilai berkelanjutan, bukan hanya benar atau salah.
4. LLM dapat diarahkan dengan memberikan deretan vektor sebagai masukan tanpa harus menuliskannya dalam bentuk kalimat (Lester dkk., 2021).

5. Penyeragaman sinyal berbasis geometri Riemann membantu model BCI tetap bekerja pada orang yang berbeda (Zanini dkk., 2018).

Berdasarkan premis-premis tersebut, hipotesis tugas akhir ini adalah sebagai berikut:

1. Kesesuaian teks yang dihasilkan LLM
   - H_0: Proporsi teks yang dinilai sesuai dengan kata yang dimaksud oleh penilai manusia tidak berbeda signifikan dengan tingkat tebakan acak.
   - H_1: Proporsi teks yang dinilai sesuai dengan kata yang dimaksud oleh penilai manusia lebih tinggi secara signifikan dibandingkan tingkat tebakan acak.
2. Akurasi vektor makna dibandingkan klasifikasi
   - H_0: Tidak terdapat perbedaan signifikan antara akurasi pengenalan kata model vektor makna dan model klasifikasi yang dilatih pada data yang sama.
   - H_1: Terdapat perbedaan signifikan antara akurasi pengenalan kata model vektor makna dan model klasifikasi yang dilatih pada data yang sama.
3. Pengaruh RCT terhadap *robustness* model dari sisi subjek pelatihan
   - H_0: Tidak terdapat perbedaan signifikan antara akurasi model dengan RCT dan model tanpa RCT pada pengujian lintas subjek.
   - H_1: Terdapat perbedaan signifikan antara akurasi model dengan RCT dan model tanpa RCT pada pengujian lintas subjek.

I.6 Metodologi

Dalam menyelesaikan tugas akhir ini, metodologi penelitian disusun sebagai berikut.

1. **Investigasi Permasalahan**
   Investigasi dilakukan dengan mengumpulkan data dan fakta mengenai hilangnya kemampuan komunikasi akibat stroke dan afasia, seperti prevalensi stroke di Indonesia dan proporsi penderita stroke yang mengalami afasia. Selain itu, dikumpulkan pula fakta mengenai keterbatasan sistem *imagined speech* berbasis EEG saat ini, terutama dari sisi akurasi, cara penilaian, dan bentuk keluarannya. Hasil investigasi ini digunakan untuk merumuskan masalah, tujuan, dan hipotesis tugas akhir.
2. **Studi Literatur**
   Studi literatur dilakukan dengan mencari, mengelompokkan, dan menapis sumber dari basis data akademik seperti Google Scholar dan arXiv. Literatur dikelompokkan ke dalam empat kategori, yaitu (a) BCI dan *imagined spe-*

ech berbasis EEG, (b) *decoding* sinyal otak menjadi representasi makna, (c) penyampaian konteks kepada LLM dalam bentuk vektor, dan (d) penyeragaman sinyal EEG antar orang. Kata kunci yang digunakan antara lain "*imagined speech EEG*", "*brain-to-text decoding*", "*soft prompt*", dan "*Riemannian alignment EEG*". Literatur diprioritaskan pada publikasi yang melaporkan hasil secara terukur, dan hasilnya dijelaskan secara komprehensif di Bab II.

3. **Analisis Kebutuhan**

   Analisis kebutuhan dilakukan melalui kajian literatur dan analisis situasi, belum melalui wawancara langsung dengan pasien atau tenaga medis. Dari hasil ini diidentifikasi masalah pengguna, lalu diturunkan kebutuhan fungsional dan nonfungsional sistem. Selanjutnya dipertimbangkan beberapa alternatif solusi yang disaring dengan syarat wajib yang diturunkan dari kebutuhan, sedangkan pendekatan klasifikasi ke label kata dipertahankan sebagai pembanding. Hasil analisis kebutuhan dijelaskan secara rinci di Bab III.

4. **Perancangan Solusi**

   Perancangan dilakukan secara bertahap dari gambaran umum ke rincian komponen. Pada tingkat umum, sistem digambarkan sebagai alur dari sinyal EEG hingga teks keluaran LLM. Pada tingkat rinci, sistem dipecah menjadi tiga bagian, yaitu (a) prapemrosesan, berupa penyiapan sinyal EEG dan pengubahan label teks menjadi vektor makna menggunakan model *sentence embedding*, (b) pemetaan, berupa penyeragaman sinyal dengan *Riemannian Centering Transformation* (RCT) lalu pemetaan sinyal ke vektor makna menggunakan model regresi, dan (c) perangkaian teks, berupa pemisahan makna yang tercampur menggunakan *Sparse Autoencoder* (SAE), penerjemahan vektor oleh *adapter*, dan perangkaian teks oleh LLM. Model *sentence embedding* dipilih karena sebagian label berupa frasa, sehingga satu label tetap menghasilkan satu vektor. Rancangan digambarkan menggunakan diagram alur (*flowchart*) untuk setiap tingkatan.

5. **Implementasi**

   Sistem diimplementasikan menggunakan bahasa Python. Pengolahan sinyal EEG dilakukan dengan MNE-Python, penyeragaman sinyal dengan pyRiemann, dan pengubahan label teks menjadi vektor makna dengan *library* sentence-transformers menggunakan model all-MiniLM-L6-v2. Model regresi, model klasifikasi pembanding, SAE, dan *adapter* dilatih menggunakan scikit-learn dan PyTorch. LLM yang digunakan adalah Qwen yang dijalankan secara lokal melalui *library* Transformers. Apabila *adapter* saja belum menghasilkan teks yang sesuai, LLM disesuaikan secara ringan menggunakan *Low-Rank*

Adaptation (LoRA) melalui *library* PEFT.

6. **Evaluasi**
   Evaluasi dilakukan dalam dua skema pengujian, yaitu per orang, ketika model dilatih dan diuji pada data orang yang sama, dan lintas subjek, ketika model dilatih pada data semua orang kecuali satu lalu diuji pada orang tersebut secara bergantian. Metrik evaluasi mencakup (a) akurasi pengenalan kata model vektor makna dibandingkan dengan model klasifikasi, (b) akurasi model dengan dan tanpa RCT pada pengujian lintas subjek, serta (c) proporsi teks yang dinilai sesuai dengan kata yang dimaksud oleh penilai manusia. Perbandingan (a) dan (b) diuji menggunakan uji Wilcoxon, sedangkan (c) diuji menggunakan uji proporsi.
7. **Penarikan Kesimpulan dan Saran**
   Hasil evaluasi digunakan untuk menjawab ketiga rumusan masalah dan menentukan apakah setiap hipotesis diterima atau ditolak. Kesimpulan disertai saran untuk pengembangan lebih lanjut, misalnya pengujian langsung pada penderita afasia dan perluasan ke kosakata yang lebih besar.

I.7 Sistematika Penulisan

Proposal tugas akhir ini disusun dalam lima bab dengan sistematika sebagai berikut.

1. **Bab I Pendahuluan** berisi latar belakang mengenai hilangnya kemampuan komunikasi pada penderita gangguan saraf serta keterbatasan sistem *imagined speech* berbasis EEG saat ini, rumusan masalah, tujuan dan ukuran keberhasilan, ruang lingkup dan batasan masalah, hipotesis, metodologi, serta sistematika penulisan.
2. **Bab II Studi Literatur** berisi kajian pustaka mengenai BCI dan *imagined speech* berbasis EEG, *decoding* sinyal otak menjadi representasi makna, penyampaian konteks kepada LLM dalam bentuk vektor, dan penyeragaman sinyal EEG antar orang, beserta hasil-hasil penelitian sebelumnya yang mendukung tugas akhir ini.
3. **Bab III Analisis Masalah** berisi analisis kondisi sistem *imagined speech* berbasis EEG saat ini, analisis kebutuhan yang mencakup identifikasi masalah pengguna serta kebutuhan fungsional dan nonfungsional, serta analisis pemilihan solusi dari beberapa alternatif yang dipertimbangkan.
4. **Bab IV Desain Konsep Solusi** berisi rancangan konsep sistem, mulai dari prapemrosesan sinyal EEG, penyeragaman sinyal dengan RCT, pemetaan sinyal ke vektor makna, hingga perangkaian teks oleh LLM, beserta perbandingannya dengan pendekatan klasifikasi yang digunakan saat ini.
5. **Bab V Rencana Selanjutnya** berisi rencana implementasi beserta alat dan

lingkungan yang dibutuhkan, rancangan pengujian untuk ketiga hipotesis, serta analisis risiko dan mitigasinya.

BAB II

STUDI LITERATUR

Bab ini membahas pustaka yang menjadi dasar pengembangan sistem pembaca maksud pengguna dari sinyal EEG saat *imagined speech*, serta penelitian terkait. Pembahasan dimulai dari antarmuka otak-komputer (BCI) beserta alur kerjanya, yaitu perekaman sinyal, pemrosesan sinyal, tantangan, dan aplikasi, lalu *imagined speech*. Setelah itu, komponen yang akan digunakan dijelaskan sesuai dengan urutan kerjanya, yaitu EEG beserta *dataset*-nya, penyeragaman sinyal antar subjek, vektor makna, *sparse autoencoder*, serta LLM beserta *soft prompt*, *adapter*, dan LoRA. Bab ditutup dengan metrik evaluasi dan penelitian terkait yang menunjukkan celah penelitian.

II.1 *Brain-Computer Interface* (BCI)

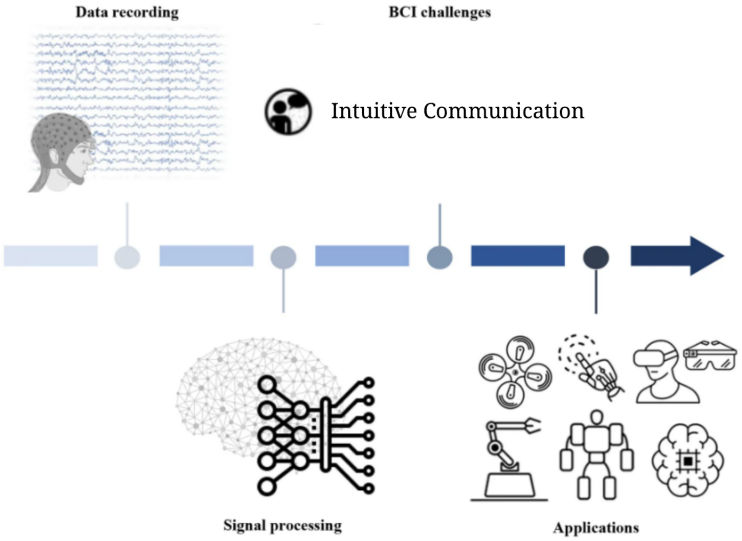
Antarmuka otak-komputer (*brain-computer interface* atau BCI) adalah sistem perangkat keras dan perangkat lunak yang memungkinkan aktivitas otak saja mengendalikan komputer atau perangkat luar (Nicolas-Alonso & Gomez-Gil, 2012). BCI menyediakan jalur baru untuk mengirim pesan dan perintah dari otak ke dunia luar tanpa melalui otot (Wolpaw dkk., 2002). Caranya, sinyal otak diubah menjadi keluaran yang menyampaikan maksud penggunanya (Wolpaw & McFarland, 2004). Teknologi ini terutama ditujukan bagi orang dengan gangguan saraf dan otot berat, misalnya ALS dan stroke batang otak, yang kehilangan jalur normal untuk berkomunikasi (Wolpaw dkk., 2002).

II.1.1 Alur Kerja BCI

Menurut Nicolas-Alonso dan Gomez-Gil (2012), BCI umumnya bekerja melalui lima langkah berurutan. Langkah pertama adalah akuisisi sinyal, yaitu merekam aktivitas otak. Langkah kedua adalah peningkatan sinyal, yaitu mengurangi artefak (gangguan yang bukan berasal dari aktivitas otak yang dimaksud). Langkah ketiga adalah ekstraksi fitur, yaitu mengambil ciri penting dari sinyal. Langkah keempat adalah klasifikasi, yaitu menerjemahkan ciri tersebut menjadi perintah atau informasi, dan langkah kelima adalah aplikasi, yaitu perangkat yang menjalankan perintah

tersebut.

Pada Gambar II.1, langkah-langkah tersebut dikelompokkan menjadi empat bagian. Bagian pertama adalah perekaman sinyal (akuisisi sinyal). Bagian kedua adalah pemrosesan sinyal (peningkatan sinyal, ekstraksi fitur, dan klasifikasi). Bagian ketiga adalah tantangan BCI, yaitu persoalan yang masih dihadapi dan dipilih sebagai fokus penelitian. Bagian keempat adalah aplikasi. Setiap bagian dijelaskan pada subbab berikut.



Gambar II.1 Alur kerja BCI, mulai dari perekaman data, pemrosesan sinyal, hingga aplikasi, beserta tantangan yang menjadi fokus penelitian ini (diadaptasi dari Jeong dkk., 2022, lisensi CC BY)

II.1.1.1 Perekaman Sinyal Otak

Sinyal otak dapat direkam dengan beberapa metode yang dikelompokkan berdasarkan aktivitas yang diukur, yaitu listrik (EEG dan ECoG), magnetik (MEG), dan metabolik (fMRI dan fNIRS) (Nicolas-Alonso & Gomez-Gil, 2012). Perbandingan utamanya ada pada resolusi waktu (seberapa cepat perubahan aktivitas dapat terbaca), resolusi ruang (seberapa tepat lokasi aktivitas dapat ditentukan), risiko bagi pengguna, dan portabilitas. Perbandingan ini ditunjukkan pada Tabel II.1.

Tabel II.1 Perbandingan metode perekaman sinyal otak untuk BCI

Metode	**Aktivitas yang diukur**	**Resolusi waktu (detik)**	**Resolusi ruang (mm)**	**Risiko**	**Portabilitas**
EEG	Listrik	∼0,05	∼10	Non-invasif	Portabel
MEG	Magnetik	∼0,05	∼5	Non-invasif	Tidak portabel
ECoG	Listrik	∼0,003	∼1	Invasif	Portabel
fMRI	Metabolik	∼1	∼1	Non-invasif	Tidak portabel
fNIRS	Metabolik	∼1	∼5	Non-invasif	Portabel

Sumber: diolah dari Nicolas-Alonso & Gomez-Gil (2012). Nilai resolusi merupakan perkiraan.

ECoG menghasilkan sinyal paling tajam dari sisi waktu maupun lokasi, tetapi bersifat invasif karena elektrodanya diletakkan di permukaan otak melalui operasi (Nicolas-Alonso & Gomez-Gil, 2012). fMRI dan fNIRS merekam aktivitas otak lewat perubahan aliran darah sehingga keduanya sama-sama lambat (Frey dkk., 2014). fMRI sangat teliti dari sisi lokasi, tetapi alatnya berukuran besar, mengelilingi seluruh tubuh pengguna, dan berharga sekitar satu juta dolar AS (Frey dkk., 2014). MEG menangkap perubahan sama cepatnya dengan EEG, tetapi alatnya tidak dapat dipindahkan (Nicolas-Alonso & Gomez-Gil, 2012).

Setiap metode punya kompromi, sehingga pemilihannya bergantung pada kebutuhan. Alat bantu bagi penderita gangguan komunikasi perlu dipakai di samping pasien, tanpa operasi, dan dengan biaya yang terjangkau. EEG memenuhi syarat tersebut karena merekam sinyal dari kulit kepala, dapat dibawa, dan menangkap perubahan sinyal dengan cepat (Nicolas-Alonso & Gomez-Gil, 2012). Dibandingkan alat perekam otak lainnya, EEG dinilai memberikan kompromi terbaik antara ketelitian, kepraktisan, dan biaya (Frey dkk., 2014).

Kelemahan EEG adalah ketelitian lokasinya yang lebih rendah, yaitu sekitar 10 mm (Nicolas-Alonso & Gomez-Gil, 2012). Sinyalnya juga lemah dan mudah tercampur gangguan dari otot dan gerakan mata, sehingga membaca sinyal otak saat *imagined speech* (Subbab II.1.2) dari EEG masih sulit (López-Bernal dkk., 2022). Kelemahan ini diterima karena kebutuhan utamanya adalah kepraktisan bagi pasien, dan akan

diatasi melalui pengolahan sinyal dan model yang dijelaskan pada subbab berikutnya.

II.1.1.2 Pemrosesan Sinyal

Sinyal EEG mentah mengandung banyak gangguan sehingga perlu dibersihkan sebelum dipakai. Gangguan yang umum adalah artefak, yaitu sinyal yang tidak berasal dari aktivitas otak yang dimaksud, misalnya dari kedipan mata dan gerakan otot (Urigüen & Garcia-Zapirain, 2015). Pra-pemrosesan juga menjadi salah satu fokus utama dalam tinjauan penelitian *imagined speech* berbasis EEG (López-Bernal dkk., 2022).

Selain bersih, data juga harus seragam. Model pembelajaran mesin umumnya menerima masukan dengan ukuran tetap, sehingga seluruh rekaman perlu memiliki jumlah *channel*, *sampling rate*, panjang rekaman, dan rentang amplitudo yang sama. Rekaman dari subjek, sesi, atau *dataset* yang berbeda sering kali berbeda dalam hal-hal tersebut, misalnya karena alat perekam yang tidak sama. Istilah *channel* dan *sampling rate* dijelaskan pada Subbab II.2.1.

Zhou dkk. (2025) memakai rangkaian langkah yang umum untuk mencapai keseragaman itu. Pertama, *band-pass filter* menahan frekuensi yang terlalu rendah (pergeseran lambat) dan terlalu tinggi (gangguan acak). Kedua, *notch filter* membuang dengung listrik dari jaringan listrik. Ketiga, sinyal diubah ke *sampling rate* yang sama (*resampling*). Keempat, amplitudo sinyal diskalakan ke rentang yang sama agar nilainya seragam antar rekaman.

Penyamaan *sampling rate* ke nilai yang lebih rendah perlu didahului *low-pass filter*, yaitu penyaring yang membuang frekuensi tinggi, agar tidak muncul gangguan *aliasing*, yaitu frekuensi tinggi yang terbaca sebagai frekuensi rendah yang palsu (Oppenheim & Schafer, 2010). Jumlah *channel* dapat disamakan dengan memilih *channel* yang dimiliki semua rekaman. Setelah itu, sinyal dipotong menjadi percobaan (*trial*), yaitu potongan sinyal untuk satu kata, sesuai rentang waktu saat subjek membayangkannya. Penyeragaman sinyal antar subjek dibahas pada Subbab II.3, dan pemetaan sinyal ke vektor makna dibahas pada Subbab II.4.

II.1.1.3 Tantangan BCI

BCI masih memiliki banyak tantangan yang berbeda-beda. Kompetisi BCI internasional 2020 mengangkat lima tantangan teknis, masing-masing dengan *dataset*-nya sendiri (Jeong dkk., 2022). Pertama, *few-shot EEG learning*, yaitu belajar dari data kalibrasi yang sangat sedikit untuk setiap pengguna. Kedua, *micro-sleep detection*,

yaitu mendeteksi tidur yang sangat singkat dari satu *channel*. Ketiga, *imagined speech decoding* untuk komunikasi BCI yang intuitif (*intuitive communication*), yaitu pengguna menyampaikan kata atau frasa utuh secara langsung, bukan mengeja huruf satu per satu. Keempat, *cross-session classification* gerakan lengan atas, yaitu menjaga ketepatan model walaupun sinyal direkam pada sesi yang berbeda. Kelima, deteksi ERP pada kondisi bergerak (*ambulatory environment*), yaitu perekaman saat pengguna tidak duduk diam di laboratorium.

Dari lima tantangan tersebut, penelitian ini hanya akan berfokus pada komunikasi yang membaca maksud pengguna dari pikirannya tanpa stimulus dari luar. Bentuk yang dipilih adalah *imagined speech*, yaitu pengguna membayangkan mengucapkan kata dalam hati.

II.1.1.4 Aplikasi BCI

Hasil terjemahan sinyal otak diteruskan ke aplikasi, yaitu perangkat yang menjalankan perintah atau menyampaikan informasi dari pengguna (Nicolas-Alonso & Gomez-Gil, 2012). Aplikasi BCI beragam, misalnya mengendalikan robot, *drone*, dan perangkat realitas virtual seperti pada Gambar II.1.

Dalam penelitian ini, aplikasi yang dituju adalah alat bantu komunikasi bagi orang yang tidak dapat berbicara. Penderita gangguan saraf dan otot berat seperti ALS dan stroke batang otak bisa saja tahu apa yang ingin disampaikan, tetapi kesulitan mengeluarkannya lewat ucapan maupun tulisan (Wolpaw dkk., 2002). Setelah stroke, hingga 40% penderita mengalami afasia, yaitu gangguan berbahasa akibat kerusakan jaringan bahasa di otak (Cochrane dkk., 2025).

II.1.2 *Imagined Speech*

Imagined speech adalah kondisi ketika seseorang membayangkan mengucapkan sebuah kata dalam hati tanpa menggerakkan mulut atau bersuara, dan sinyal EEG pada saat itu direkam untuk dibaca. Sinyal ini dapat menjadi jalur komunikasi baru bagi orang yang tidak mampu berbicara akibat disabilitas motorik atau penyakit saraf (López-Bernal dkk., 2022). Pendekatan yang umum digunakan adalah klasifikasi, yaitu model dilatih untuk memilih satu kata dari daftar kata target yang sudah ditentukan sebelumnya (López-Bernal dkk., 2022). Selain klasifikasi ke daftar kata tetap, ada pendekatan lain yang memetakan sinyal otak ke representasi makna (Tang dkk., 2023), yang dibahas pada Subbab II.4.

Hasil klasifikasi *imagined speech* sangat bergantung pada jenis tugasnya. Menurut Duhair dkk. (2026), tugas dengan dua pilihan sering melaporkan akurasi di atas 80

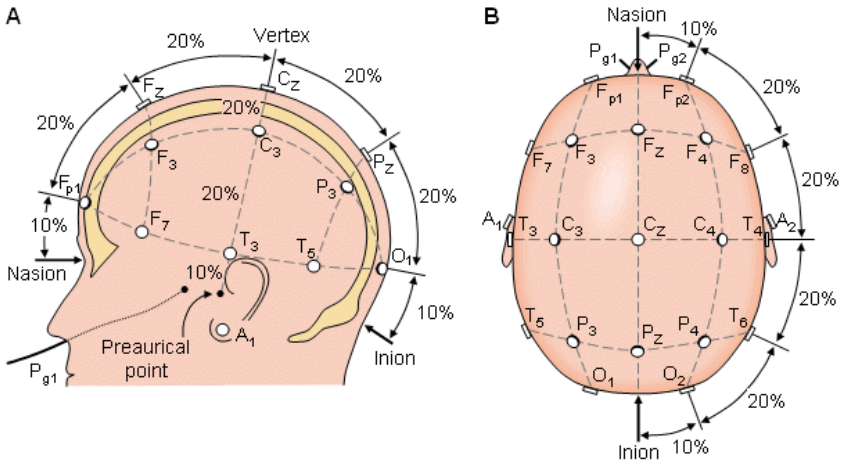
persen, tetapi pengenalan kata atau fonem dengan banyak pilihan memberikan hasil yang sangat beragam dan peka terhadap rancangan *dataset* serta cara pengujian.

Ada tiga tantangan utama. Pertama, sinyal EEG saat *imagined speech* memiliki rasio sinyal terhadap gangguan (*signal-to-noise ratio* atau SNR) yang rendah (López-Bernal dkk., 2022). Kedua, sinyal berbeda cukup besar antar orang, sementara data yang tersedia masih kecil dan beragam (Duhair dkk., 2026). Ketiga, metode invasif seperti ECoG rata-rata menghasilkan akurasi klasifikasi yang lebih tinggi daripada metode non-invasif (López-Bernal dkk., 2022).

II.2 EEG

II.2.1 Cara Kerja EEG

EEG merekam aktivitas listrik otak lewat elektroda yang ditempelkan di kulit kepala. Penempatan elektroda umumnya mengikuti sistem internasional 10-20, yaitu jarak antar elektroda diatur pada kelipatan 10 atau 20 persen dari jarak depan-belakang dan kiri-kanan kepala (Britton dkk., 2016). Nama setiap elektroda terdiri atas huruf dan angka. Huruf menunjukkan bagian otak di bawahnya (F untuk frontal, T untuk temporal, P untuk parietal, dan O untuk oksipital), angka ganjil berada di sisi kiri kepala, angka genap di sisi kanan, dan huruf z di garis tengah (Britton dkk., 2016). Setiap elektroda menghasilkan satu rangkaian sinyal yang disebut *channel*, seperti terlihat pada Gambar II.2.



Gambar II.2 Sistem internasional 10-20 dilihat dari kiri (A) dan atas kepala (B) (sumber: Malmivuo & Plonsey, 1995)

Sinyal EEG dikelompokkan menurut frekuensinya, yaitu jumlah gelombang per detik dengan satuan Hz. Gelombang delta berfrekuensi 1 sampai 3 Hz, theta 4 sampai 7 Hz, alpha 8 sampai 12 Hz, dan beta 13 Hz ke atas, sedangkan frekuensi di atas 25

Hz (gamma) jarang terlihat pada EEG kulit kepala (Britton dkk., 2016). Rekaman EEG berupa deretan angka untuk setiap *channel* pada setiap titik waktu, dan jumlah titik data yang diambil per detik disebut *sampling rate*.

II.2.2 *Dataset* EEG *Imagined Speech*

Salah satu *dataset* publik untuk *imagined speech* adalah BCI Competition 2020-3, yang dirilis dalam kompetisi BCI internasional 2020 (Jeong dkk., 2022). Sebanyak 15 subjek diminta membayangkan lima kata atau frasa, yaitu *"hello"*, *"help me"*, *"stop"*, *"thank you"*, dan *"yes"*. EEG direkam dari 64 *channel* dengan *sampling rate* 256 Hz, dan setiap sampel berupa rekaman selama 3 detik (Zhou dkk., 2025).

Pembagian data ditentukan oleh kompetisi. Untuk setiap subjek tersedia 60 percobaan per kata untuk pelatihan, 10 untuk validasi, dan 10 untuk pengujian, sehingga totalnya 6.000 percobaan (Jeong dkk., 2022; Zhou dkk., 2025).

II.3 Penyeragaman Sinyal Antar Subjek dengan RCT

Sinyal EEG untuk kata yang sama berbeda cukup besar dari satu orang ke orang lain (Duhair dkk., 2026), sehingga model yang dilatih pada satu orang sulit dipakai pada orang lain. Salah satu cara mengatasinya adalah *transfer learning* berbasis geometri Riemann. Cara ini merepresentasikan data lewat matriks kovarians spasial, lalu menggeser data setiap subjek ke acuan yang sama agar data antar subjek dapat dibandingkan (Zanini dkk., 2018). Dalam proposal ini, pemusatan tersebut disebut *Riemannian Centering Transformation* (RCT).

Matriks kovarians spasial adalah tabel berukuran $N \times N$, dengan N jumlah *channel*, yang menunjukkan seberapa kuat setiap pasang *channel* naik dan turun bersamaan. Untuk satu percobaan dengan sinyal X berukuran N *channel* $\times$ T titik waktu, matriks ini dihitung dengan Persamaan II.1. Karena waktu sudah diringkas, ukuran matriksnya tetap $N \times N$ berapa pun panjang rekaman.

$$C_i = \frac{1}{T-1} X_i X_i^\top \tag{II.1}$$

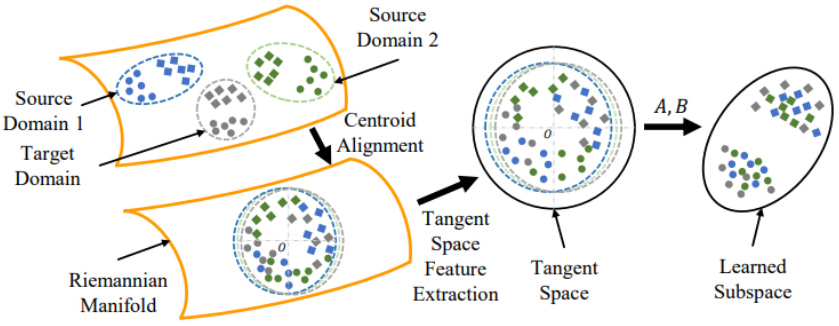
Matriks kovarians tidak berada pada ruang datar biasa, melainkan pada ruang lengkung yang disebut *manifold* Riemann. Karena itu, rata-rata yang tepat adalah rata-rata Riemann (rata-rata geometrik), yaitu matriks yang meminimalkan jumlah kuadrat jarak Riemann ke semua matriks lainnya (He & Wu, 2020), seperti pada Persamaan II.2. Pemusatan kemudian dilakukan dengan Persamaan II.3, sehingga rata-

rata baru setiap subjek menjadi matriks identitas (Zanini dkk., 2018).

$$\bar{C} = \arg\min_{C \succ 0} \sum_{i=1}^{M} \delta_R^2(C, C_i) \tag{II.2}$$

$$\tilde{C}_i = \bar{C}^{-1/2} \, C_i \, \bar{C}^{-1/2} \tag{II.3}$$

Pada persamaan tersebut, M adalah jumlah percobaan satu subjek, δ_R adalah jarak Riemann, dan $\bar{C}$ adalah rata-rata Riemann milik subjek itu. Operasi ini setara dengan *whitening*, yaitu penyeragaman sebaran sinyal, memakai rata-rata Riemann (Bleuzé dkk., 2022). Jarak antar matriks pada subjek yang sama tidak berubah, tetapi data setiap subjek bergeser ke titik acuan yang sama sehingga lebih mudah dibandingkan (He & Wu, 2020). Prosesnya tidak memerlukan label kata, tetapi memerlukan sejumlah rekaman dari subjek tersebut untuk menghitung rata-ratanya. Ilustrasi pemusatan ditunjukkan pada Gambar II.3.



Gambar II.3 Alur MEKT: penyelarasan pusat data pada *manifold* Riemann, pemetaan ke *tangent space*, lalu pembelajaran subruang (sumber: Zhang & Wu, 2020)

Banyak model pembelajaran mesin menerima masukan berupa vektor, sehingga matriks kovarians yang sudah dipusatkan perlu diubah menjadi vektor terlebih dahulu. Salah satu caranya adalah memetakan matriks tersebut ke *tangent space*, yaitu ruang datar di sekitar titik acuan (Barachant dkk., 2012). Zanini dkk. (2018) menguji pemusatan ini pada BCI gerakan yang dibayangkan (*motor imagery*) dan respons potensial otak (ERP), sedangkan penerapannya pada *imagined speech* belum ditemukan pada literatur yang ditelaah dalam studi ini.

II.4 Vektor Makna dan Pemetaan EEG ke Vektor

II.4.1 Vektor Makna

Komputer tidak membaca makna dari huruf. Cara umum untuk menyampaikan makna ke komputer adalah mengubah data, misalnya kata atau kalimat, menjadi vektor, yaitu deretan angka, yang disebut *embedding*. Kata atau kalimat yang maknanya dekat mendapat vektor yang berdekatan (Reimers & Gurevych, 2019). Pereira dkk. (2018) menyebut ruang tempat vektor-vektor ini berada sebagai ruang semantik, yang dibangun dari kumpulan teks yang sangat besar.

Konsep *embedding* tidak terbatas pada teks. Gambar, misalnya, dapat diubah menjadi vektor oleh model CLIP (Mokady dkk., 2021), dan data pencitraan otak dapat dipetakan ke vektor dalam ruang semantik yang sama dengan teks (Pereira dkk., 2018). Dengan cara ini, sinyal otak dan kata dapat dibandingkan dalam satu ruang vektor, sehingga kedekatan maknanya dapat diukur dengan ukuran yang sama.

Kedekatan dua vektor, baik yang berasal dari teks maupun dari sinyal, diukur dengan *cosine similarity*, seperti pada Persamaan II.4 dan diilustrasikan pada Gambar II.4. Nilainya 1 bila arah kedua vektor sama persis, yang berarti maknanya sangat dekat, dan makin kecil bila maknanya makin berbeda. Ukuran ini memberi nilai kedekatan yang bertingkat, bukan sekadar benar atau salah.

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \, \|\mathbf{b}\|} \tag{II.4}$$

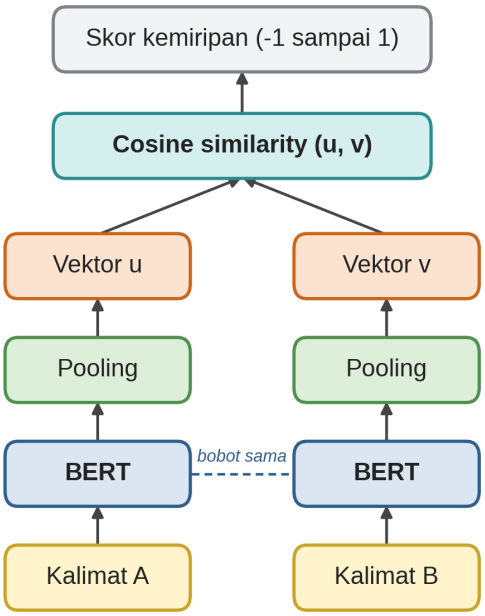


Gambar II.4 Ilustrasi ruang semantik dua dimensi, dengan kata-kata yang maknanya berdekatan membentuk kelompok (sumber: Pereira dkk., 2018)

II.4.2 Model *Sentence Embedding*

Vektor makna dihasilkan oleh model *embedding*. Model *sentence embedding* menghasilkan satu vektor berukuran tetap untuk satu kalimat atau frasa dengan panjang berapa pun, sehingga teks yang berbeda panjang dapat dibandingkan dalam ruang vektor yang sama (Reimers & Gurevych, 2019).

Salah satu pendekatan *sentence embedding* adalah Sentence-BERT (SBERT), yaitu modifikasi dari jaringan BERT yang sudah dilatih sebelumnya. BERT sendiri tidak menghasilkan vektor kalimat yang berdiri sendiri, sehingga sulit dipakai untuk mencari kalimat yang maknanya mirip (Reimers & Gurevych, 2019). SBERT menambahkan operasi *pooling*, misalnya merata-ratakan vektor semua *token* keluaran BERT, untuk mendapat satu vektor berukuran tetap. Jaringan itu kemudian dilatih ulang dengan struktur *siamese* dan *triplet*, yaitu dua atau tiga salinan jaringan dengan bobot yang sama yang dipasangkan pada pasangan kalimat, agar kalimat yang maknanya mirip berdekatan dalam ruang vektor dan dapat dibandingkan dengan *cosine similarity* (Reimers & Gurevych, 2019). Arsitektur SBERT saat menghitung kemiripan dua kalimat ditunjukkan pada Gambar II.5.



Gambar II.5 Arsitektur SBERT saat menghitung kemiripan dua kalimat (diadaptasi dari Reimers & Gurevych, 2019)

II.4.3 Pemetaan Sinyal Otak ke Vektor Makna

Pereira dkk. (2018) membangun *decoder* yang memetakan data pencitraan otak ke vektor dalam ruang semantik. *Decoder* dilatih dari data konsep tunggal, lalu mampu mengenali makna kalimat baru dengan topik yang tidak muncul saat pelatihan, dan hasilnya menangkap struktur kemiripan makna antar kalimat. Tang dkk. (2023) melanjutkan arah ini dengan merekonstruksi bahasa secara berkelanjutan, sehingga menghasilkan rangkaian kata yang maknanya sesuai dengan ucapan yang dibayangkan seseorang. Kedua penelitian tersebut memakai data pencitraan otak fMRI, bukan EEG.

Pemetaan dari sinyal otak ke vektor makna pada dasarnya adalah masalah regresi, yaitu memprediksi angka-angka penyusun vektor makna dari fitur sinyal. Model belajar dari pasangan data berupa fitur sinyal dan vektor makna dari kata yang sedang diproses otak, dengan meminimalkan selisih antara vektor prediksi dan vektor target, seperti pada Persamaan II.5. Bentuk modelnya beragam, mulai dari regresi linear sampai jaringan saraf.

$$\hat{\theta} = \arg\min_{\theta} \sum_{i=1}^{M} \|\mathbf{y}_i - f_\theta(\mathbf{x}_i)\|_2^2 \tag{II.5}$$

Pada persamaan tersebut, M adalah jumlah percobaan, $\mathbf{x}_i$ adalah fitur sinyal pada percobaan ke-i, $\mathbf{y}_i$ adalah vektor makna targetnya, f_θ adalah model dengan parameter θ, dan $\hat{\theta}$ adalah parameter terbaik hasil pelatihan. Vektor hasil prediksi dapat diterjemahkan kembali menjadi kata dengan mencari kata kandidat yang vektornya paling dekat menurut *cosine similarity*.

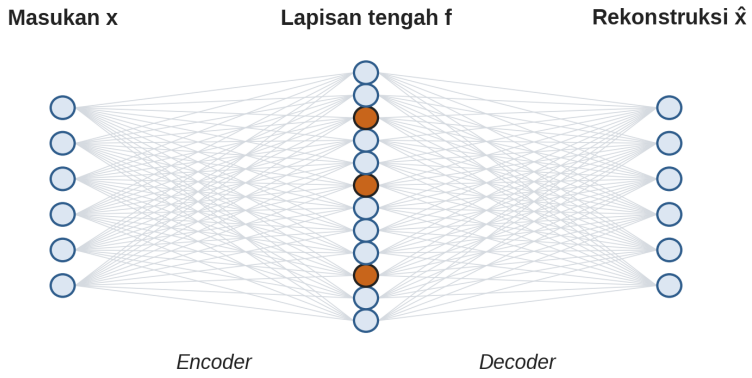
II.5 *Sparse Autoencoder* (SAE)

Autoencoder adalah jaringan saraf yang belajar mengubah sebuah vektor menjadi bentuk lain, lalu mengembalikannya sedekat mungkin ke vektor semula. Pada *sparse autoencoder* (SAE), bentuk di tengahnya dibuat lebih lebar daripada vektor asli, tetapi hanya sedikit angka yang boleh aktif pada satu waktu (Bricken dkk., 2023; Cunningham dkk., 2023). Pelatihannya meminimalkan galat rekonstruksi ditambah penalti pada jumlah angka yang aktif, seperti pada Persamaan II.6.

$$\mathcal{L} = \|\mathbf{x} - \hat{\mathbf{x}}\|_2^2 + \alpha\|\mathbf{f}\|_1 \tag{II.6}$$

Pada persamaan tersebut, **x** adalah vektor masukan, **f** adalah angka-angka di lapisan tengah yang lebih lebar, $\hat{\mathbf{x}}$ adalah hasil rekonstruksi, dan α adalah kekuatan penalti agar sedikit angka yang aktif.

SAE digunakan dalam penelitian interpretabilitas model bahasa karena sebuah dimensi pada vektor sering aktif untuk beberapa makna yang tidak berhubungan, yang disebut polisemantik. Salah satu dugaan penyebabnya adalah superposisi, yaitu jaringan menyimpan lebih banyak ciri daripada jumlah dimensinya dengan menempatkannya pada arah-arah yang saling tumpang tindih (Cunningham dkk., 2023). SAE memisahkan arah-arah ini, dan hasilnya berupa ciri yang lebih mudah ditafsirkan dan lebih bersifat satu makna dibandingkan metode pembanding (Bricken dkk., 2023; Cunningham dkk., 2023). Penerapan SAE yang dilaporkan pada kedua penelitian tersebut adalah pada aktivasi di dalam model bahasa. Struktur SAE ditunjukkan pada Gambar II.6.



Gambar II.6 Ilustrasi struktur *sparse autoencoder*, dengan unit yang aktif ditandai warna oranye

II.6 *Large Language Model* (LLM)

Model bahasa *pretrained* (*pretrained language model*) dibangun dengan melatih model Transformer pada kumpulan teks berskala besar, sehingga mampu menyelesaikan berbagai tugas pemrosesan bahasa. Istilah *large language model* (LLM) dipakai untuk model *pretrained* yang berukuran besar, misalnya berisi puluhan atau ratusan miliar parameter, yaitu angka-angka yang membentuk model (Zhao dkk., 2023).

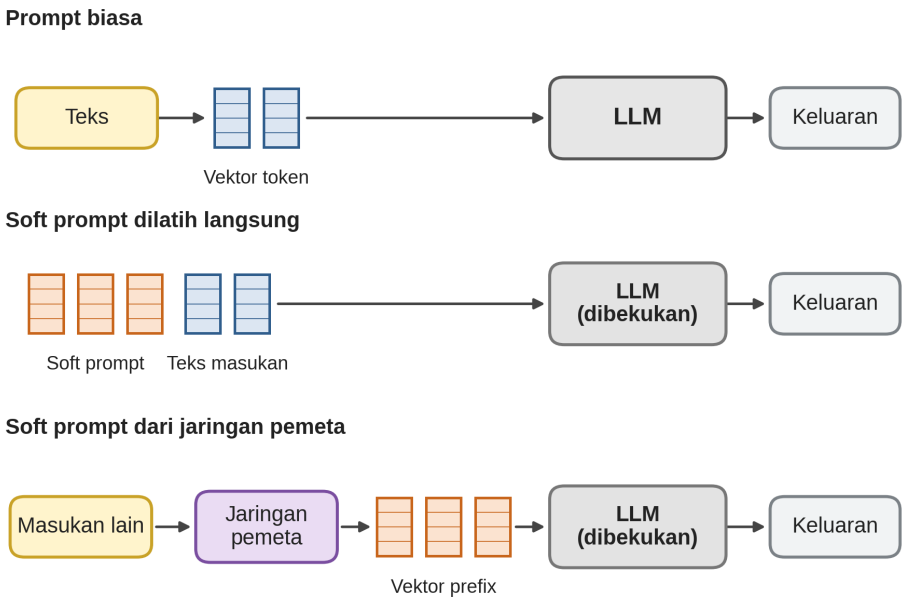
LLM tidak membaca huruf secara langsung. Teks dipecah menjadi *token*, yaitu potongan kata, lalu setiap *token* diubah menjadi vektor sebelum diproses (Mokady dkk., 2021). Karena itu, apa yang sebenarnya diterima LLM adalah deretan vektor, dan hal inilah yang memungkinkan vektor diberikan langsung tanpa melalui kata.

II.7 *Soft Prompt*

Prompt biasa adalah teks yang diubah menjadi vektor oleh LLM. *Soft prompt* adalah deretan vektor yang langsung diberikan kepada LLM di depan masukan, tanpa harus ditulis sebagai kata. Pada Lester dkk. (2021), isi vektor ini dilatih supaya LLM yang dibekukan menjalankan tugas tertentu, bukan dipilih dari kata yang ada, sehingga vektor tersebut mewakili tugas. Pendekatan serupa, yaitu *prefix-tuning*, menambahkan vektor khusus tugas ke bagian dalam model (Li & Liang, 2021).

Vektor di depan masukan juga dapat dihasilkan oleh jaringan kecil dari masukan lain, sehingga isinya mewakili masukan itu dan bukan hanya tugas, dan isinya berubah pada setiap data (Mokady dkk., 2021). Dalam proposal ini, istilah *soft prompt* dipakai secara luas untuk kedua bentuk tersebut.

Lester dkk. (2021) melaporkan bahwa selisih performa antara *soft prompt* dan *fine-tuning* penuh, yaitu melatih ulang seluruh bobot model, mengecil seiring bertambahnya ukuran model. *Soft prompt* juga lebih ringan karena hanya vektor kecil yang disimpan untuk tiap tugas, sedangkan *fine-tuning* penuh menghasilkan salinan model utuh. Cara kerja *soft prompt* ditunjukkan pada Gambar II.7.



Gambar II.7 Perbandingan *prompt* biasa dan dua bentuk *soft prompt* (diadaptasi dari Lester dkk., 2021; Mokady dkk., 2021)

II.8 *Adapter*

Vektor dari satu model *embedding* tidak berada di ruang yang sama dengan vektor kata di dalam LLM, dan ukurannya pun berbeda. *Adapter* adalah jaringan kecil yang menerjemahkan vektor dari satu ruang ke ruang masukan LLM. Pada ClipCap, jaringan pemeta ringan mengubah *embedding* gambar menjadi sejumlah vektor yang berukuran sama dengan *embedding* kata, lalu menaruhnya di depan teks sebagai *prefix* untuk GPT-2 (Mokady dkk., 2021).

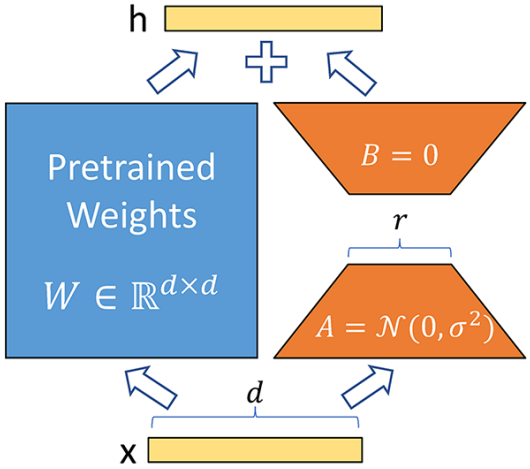
Mokady dkk. (2021) juga melaporkan bahwa metode ini tetap bekerja walaupun hanya jaringan pemeta yang dilatih, sementara model pembuat *embedding* gambar dan model bahasanya dibekukan. Hal ini menunjukkan bahwa *embedding* dari satu model dapat dipetakan ke ruang masukan model bahasa lain.

II.9 *Low-Rank Adaptation* (LoRA)

Low-Rank Adaptation (LoRA) adalah cara menyesuaikan LLM secara ringan tanpa melatih ulang seluruh bobotnya. LoRA membekukan bobot LLM dan menyisipkan matriks kecil yang dapat dilatih ke setiap lapisan Transformer (Hu dkk., 2021). Perubahan bobot dinyatakan sebagai hasil kali dua matriks kecil, seperti pada Persamaan II.7. Struktur LoRA ditunjukkan pada Gambar II.8.

$$W = W_0 + \Delta W = W_0 + BA, \quad B \in \mathbb{R}^{d\times r},\ A \in \mathbb{R}^{r\times k},\ r \ll \min(d,k) \tag{II.7}$$

Pada persamaan tersebut, W_0 adalah bobot LLM yang dibekukan dengan ukuran $d \times k$, B dan A adalah matriks kecil yang dilatih, dan r adalah peringkat (*rank*) yang jauh lebih kecil daripada d dan k. Pada GPT-3 175B, LoRA mengurangi jumlah parameter yang dilatih sebanyak 10.000 kali dan kebutuhan memori GPU sebanyak 3 kali dibandingkan *fine-tuning* penuh, dengan kualitas yang setara atau lebih baik dan tanpa tambahan waktu inferensi (Hu dkk., 2021).



Gambar II.8 Reparameterisasi LoRA: bobot *pretrained* dibekukan dan hanya matriks A dan B yang dilatih (sumber: Hu dkk., 2021)

II.10 Metrik Evaluasi dan Uji Statistik

Akurasi pengenalan kata adalah persentase percobaan yang tebakannya benar. Karena jumlah percobaan tiap kata bisa berbeda, *balanced accuracy* memakai rata-rata ketepatan untuk setiap kata, seperti pada Persamaan II.8 (Zhou dkk., 2025). Pada persamaan tersebut, C adalah jumlah kata, TP_i adalah jumlah percobaan kata ke-i yang ditebak benar, dan FN_i adalah jumlah percobaan kata ke-i yang ditebak seba-

gai kata lain.

$$\text{B-Acc} = \frac{1}{C}\sum_{i=1}^{C}\frac{TP_i}{TP_i + FN_i} \tag{II.8}$$

Pada model vektor makna, kata yang ditebak dipilih dari kata dengan *cosine similarity* (Persamaan II.4) tertinggi terhadap vektor prediksi. Dengan cara ini, model vektor makna dan model klasifikasi dapat dibandingkan memakai akurasi yang sama. Nilai *cosine similarity* juga dapat dilaporkan sebagai tingkat kedekatan antara tebakan dan kata yang dimaksud.

Pengujian dilakukan dalam dua skema. Pada skema per subjek, model dilatih dan diuji pada data subjek yang sama. Pada skema lintas subjek, model dilatih pada data semua subjek kecuali satu, lalu diuji pada subjek yang tidak dipakai tersebut, dan langkah ini diulang bergantian untuk setiap subjek.

Perbandingan antar model diuji dengan uji Wilcoxon *signed-rank*. Uji ini membandingkan dua model pada subjek-subjek yang sama dengan melihat selisih hasilnya dan peringkat selisih tersebut, tanpa mengandaikan bahwa selisihnya tersebar normal (Wilcoxon, 1945). Untuk proporsi teks yang dinilai sesuai oleh penilai manusia, dipakai uji proporsi yang membandingkan persentase yang diamati dengan persentase yang diharapkan bila hanya menebak. Perbedaan dianggap signifikan bila nilai p kurang dari 0,05.

II.11 Penelitian Terkait

Penelitian *imagined speech* berbasis EEG sebagian besar memakai klasifikasi ke daftar kata tetap (López-Bernal dkk., 2022). Pada *dataset* BCIC2020-3 dengan lima kata, model klasifikasi terbaru yang dilaporkan Zhou dkk. (2025) mencapai *balanced accuracy* sekitar 60 persen. Hasil untuk pengenalan banyak kata atau fonem secara umum sangat beragam dan peka terhadap rancangan *dataset* (Duhair dkk., 2026).

Di sisi lain, pemetaan sinyal otak ke vektor makna sudah diteliti. Pereira dkk. (2018) dan Tang dkk. (2023) melakukannya pada data fMRI. Untuk EEG *imagined speech*, NeuroSpeak (Rastogi dkk., 2026), yang dipresentasikan pada ICLR 2026, menghasilkan kalimat *imagined speech* dari EEG pada korpus CHISCO dengan lebih dari 20.000 kalimat, dan mencapai skor kemiripan semantik 47,70 persen pada evaluasi lintas subjek. Ringkasan penelitian terkait ditunjukkan pada Tabel II.2.

Berdasarkan penelitian terkait tersebut, terdapat tiga celah yang diangkat dalam pro-

posal ini. Pertama, penyeragaman sinyal dengan RCT untuk pemetaan EEG *imagined speech* ke vektor makna lintas subjek belum ditemukan pada literatur yang ditelaah dalam studi ini. Kedua, perbandingan langsung antara pemetaan ke vektor makna dan klasifikasi ke label kata pada data dan pembagian data yang sama belum ditemukan pada literatur yang ditelaah. Ketiga, penggunaan vektor makna hasil pemetaan EEG sebagai *soft prompt* untuk LLM melalui *adapter*, dengan LoRA sebagai cadangan, belum ditemukan pada literatur yang ditelaah.

Tabel II.2 Ringkasan penelitian terkait

Penelitian	**Sinyal dan tugas**	**Pendekatan**	**Catatan hasil**	**Perbedaan dengan penelitian ini**
NeuroSpeak (ICLR 2026)	EEG, *imagined speech* tingkat kalimat (CHISCO)	Penyelarasan EEG ke *embedding* bahasa, lalu dekoder teks	Kemiripan semantik 47,70% pada evaluasi lintas subjek	Penelitian ini memakai kosakata kecil dan membandingkannya langsung dengan klasifikasi
Zhou dkk. (2025)	EEG, klasifikasi *imagined speech* lima kata (BCIC2020-3)	Model fondasi EEG dengan klasifikasi	*Balanced accuracy* 0,6004	Keluarannya label diskrit, sedangkan penelitian ini memetakan ke vektor makna
Tang dkk. (2023)	fMRI, rekonstruksi bahasa berkelanjutan	*Decoder* berbasis makna dengan model bahasa	Rangkaian kata sesuai dengan makna ucapan yang dibayangkan	Memakai fMRI, bukan EEG
Mokady dkk. (2021)	Gambar, pembuatan keterangan gambar	Jaringan pemeta dari *embedding* CLIP ke *prefix* GPT-2	Berhasil walaupun hanya jaringan pemeta yang dilatih	Bukan sinyal otak, menjadi dasar penggunaan *adapter*
Zanini dkk. (2018)	EEG, *motor imagery* dan ERP	Pemusatan data berbasis geometri Riemann	Data antar subjek menjadi lebih mudah dibandingkan	Belum diterapkan pada *imagined speech*
Pereira dkk. (2018)	fMRI, makna kalimat	Pemetaan ke ruang semantik	Mengenali makna kalimat baru yang tidak muncul saat pelatihan	Memakai fMRI, bukan EEG

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

BCI adalah bidang yang masih berkembang. Tujuan jangka pendeknya adalah menyediakan kemampuan komunikasi bagi penyandang disabilitas berat (Nicolas-Alonso & Gomez-Gil, 2012), dan kebutuhan membaca sinyal otak juga muncul di bidang lain, misalnya deteksi *microsleep* yang menjadi salah satu tantangan pada kompetisi BCI 2020 (Jeong dkk., 2022). Alat perekam sinyal otak sudah tersedia dalam berbagai jenis, tetapi tidak semuanya cocok untuk pemakaian sehari-hari. ECoG memerlukan operasi, fMRI dan MEG tidak dapat dipindahkan (Nicolas-Alonso & Gomez-Gil, 2012), dan fMRI serta fNIRS merekam lewat perubahan aliran darah sehingga lambat (Frey dkk., 2014).

Di antara alat tersebut, EEG paling praktis karena tidak memerlukan operasi, dapat dibawa, dan menangkap perubahan sinyal dengan cepat (Nicolas-Alonso & Gomez-Gil, 2012). Pembacaan EEG sudah cukup memadai untuk tugas sederhana, misalnya tugas dengan dua pilihan yang sering melaporkan akurasi di atas 80 persen (Duhair dkk., 2026). Namun untuk *imagined speech* dengan banyak pilihan kata, hasilnya masih beragam (Duhair dkk., 2026), dan teknik non-invasif lebih sulit melampaui ambang akurasi sekitar 70 persen yang dianggap layak untuk penerapan nyata (López-Bernal dkk., 2022).

Di sisi lain, jumlah orang yang kehilangan kemampuan berbicara cukup besar. Prevalensi stroke di Indonesia tahun 2018 sekitar 2,1 juta orang (Riskesdas, 2018), hingga 40 persen penderita stroke mengalami afasia (Cochrane dkk., 2025), dan ALS serta stroke batang otak juga membuat penderitanya sulit berkomunikasi (Wolpaw dkk., 2002). Dengan jumlah penderita sebesar ini, alat bantu komunikasi harus dapat disediakan dalam jumlah banyak, sehingga alat yang ringan dan tidak memerlukan operasi seperti EEG lebih sesuai dibandingkan alat yang mahal dan berukuran besar.

Model konseptual sistem *imagined speech* berbasis EEG yang ada saat ini terdiri

atas empat komponen yang bekerja berurutan, yaitu perekaman EEG saat pengguna membayangkan sebuah kata, pra-pemrosesan sinyal, ekstraksi fitur, dan klasifikasi yang memilih satu kata dari daftar kata yang sudah ditentukan (López-Bernal dkk., 2022). Keluaran sistem berupa satu label kata, dan keberhasilannya dinilai benar atau salah.

Sistem tersebut memiliki tiga masalah. Pertama, akurasinya masih rendah karena sinyal EEG saat *imagined speech* memiliki rasio sinyal terhadap gangguan yang rendah, bervariasi antar orang, dan data yang tersedia terbatas (Duhair dkk., 2026; López-Bernal dkk., 2022). Kedua, penilaian benar atau salah menganggap tebakan yang maknanya dekat sama salahnya dengan tebakan yang jauh. Ketiga, keluarannya berhenti pada satu label kata, sehingga belum berupa teks utuh yang dapat dipahami langsung oleh orang di sekitar pengguna.

III.2 Analisis Kebutuhan

Berdasarkan kondisi tersebut, dibutuhkan alat yang dapat menerjemahkan pikiran seseorang menjadi kata atau bahasa yang dapat dimengerti orang lain, dengan cara menerima sinyal otak pengguna lalu menerjemahkannya. Alat ini ditujukan bagi orang yang tidak dapat berbicara, sehingga harus dapat dipakai tanpa operasi dan harus bisa menerjemahkannya dengan cepat karena digunakan untuk komunikasi.

III.2.1 Identifikasi Masalah Pengguna

Masalah pengguna diidentifikasi dari studi literatur dan analisis situasi, belum dari wawancara langsung dengan pasien atau tenaga medis. Masalah tersebut ditunjukkan pada Tabel III.1.

Tabel III.1 Identifikasi masalah pengguna

ID	Masalah pengguna	Penjelasan
M01	Pesan mendesak perlu disampaikan cepat dan spontan	Contohnya pasien di rumah sakit yang ingin meminta ke toilet. Alat bantu komunikasi yang ada hanya mencapai sekitar 5 sampai 15 kata per menit pada pemilihan langsung (Higginbotham dkk., 2009), dan sistem harus merespons cepat agar pesan tersampaikan tepat waktu.
M02	Alat harus mudah digunakan	Pengguna memerlukan alat tanpa langkah yang rumit.
M03	Jalur otot terganggu, sehingga alat tidak boleh bergantung pada gerakan	Penderita ALS dan stroke batang otak kesulitan berkomunikasi lewat otot, sehingga BCI dipandang sebagai jalur komunikasi non-otot bagi mereka (Wolpaw dkk., 2002).
M04	Akurasi pembacaan masih kurang baik	Hasil pengenalan banyak kata sangat beragam (Duhair dkk., 2026), dan teknik non-invasif lebih sulit melampaui ambang akurasi sekitar 70 persen (López-Bernal dkk., 2022).
M05	Keluaran satu kata sulit dipahami orang di sekitar pengguna	Sistem yang ada hanya mengeluarkan satu label kata, sehingga belum berupa teks utuh yang dapat dipahami langsung, seperti diuraikan pada Subbab III.1.

III.2.2 Kebutuhan Fungsional

Kebutuhan fungsional sistem ditunjukkan pada Tabel III.2.

Tabel III.2 Kebutuhan fungsional

ID	Kebutuhan fungsional	Menjawab
F01	Sistem dapat menerima sinyal EEG saat pengguna membayangkan kata atau frasa.	M04
F02	Sistem dapat membersihkan dan menyeragamkan sinyal EEG antar orang dengan RCT.	M04
F03	Sistem dapat memetakan sinyal EEG menjadi vektor makna.	M04
F04	Sistem dapat memisahkan makna yang tercampur pada vektor makna dengan SAE.	M05
F05	Sistem dapat memberikan vektor makna kepada LLM sebagai *soft prompt*.	M05
F06	Sistem dapat menghasilkan teks yang sesuai dengan maksud pengguna.	M04, M05
F07	Hasil sistem dapat dinilai, yaitu lewat akurasi pengenalan kata dan penilaian kesesuaian teks oleh penilai manusia.	M04

III.2.3 Kebutuhan Nonfungsional

Kebutuhan nonfungsional sistem ditunjukkan pada Tabel III.3.

Tabel III.3 Kebutuhan nonfungsional

ID	Kebutuhan nonfungsional	Menjawab
NF01	Sistem dapat dipakai kapan saja dan di mana saja, sehingga perekamannya harus non-invasif dan portabel.	M01, M03
NF02	Sistem menghasilkan teks dengan cepat.	M01
NF03	Sistem mudah digunakan dan dapat dipelajari dengan beberapa tahapan saja.	M02

III.3 Analisis Pemilihan Solusi

III.3.1 Alternatif Solusi

Terdapat beberapa alternatif solusi yang dipertimbangkan.

1. **Alat bantu komunikasi (*augmentative and alternative communication* atau AAC)**. Pengguna memilih huruf atau kata lewat gerakan. Kecepatannya sekitar 5 sampai 15 kata per menit pada pemilihan langsung dan 2 sampai 7 kata per menit pada pemindaian, atau 15 sampai 25 kali lebih lambat daripada ucapan (Higginbotham dkk., 2009). Kelambatan ini disebut membata-

si kesempatan pendidikan dan pekerjaan penggunanya (Higginbotham dkk., 2009).

2. **BCI invasif**. Teknik invasif seperti ECoG rata-rata menghasilkan akurasi yang lebih tinggi dan lebih mudah melampaui ambang 70 persen (López-Bernal dkk., 2022), tetapi memerlukan operasi (Nicolas-Alonso & Gomez-Gil, 2012).
3. **BCI dengan fMRI, MEG, atau fNIRS**. fMRI, MEG, atau fNIRS memiliki ketelitian yang lebih baik dibandingkan EEG yaitu sekitar 1 mm untuk fMRI dan 5 mm untuk MEG dan fNIRS, tetapi fMRI dan MEG tidak dapat dipindahkan, sedangkan fMRI dan fNIRS lambat karena merekam lewat perubahan aliran darah (Frey dkk., 2014; Nicolas-Alonso & Gomez-Gil, 2012).
4. **EEG dengan klasifikasi ke label kata**. Ini pendekatan yang umum pada *imagined speech* (López-Bernal dkk., 2022). Keluarannya satu label kata dan penilaiannya benar atau salah.
5. **EEG dengan pemetaan ke vektor makna dan LLM**. Pengguna membayangkan sebuah kata atau frasa, dan sinyal otaknya direkam dengan perangkat EEG portabel, misalnya Emotiv EPOC. Sinyal EEG diseragamkan dengan RCT, lalu model regresi yang sudah dilatih memetakannya ke vektor makna yang menyerupai keluaran model *sentence embedding*. Makna yang tercampur pada vektor tersebut dipisahkan dengan *Sparse Autoencoder* (SAE). Vektor hasil pemisahan diterjemahkan oleh *adapter*, dengan LoRA sebagai cadangan, menjadi *soft prompt* bagi LLM, dan LLM menghasilkan teks.

Pada alternatif kelima terdapat tiga pilihan rancangan yang dipertimbangkan. Pertama, vektor dapat diubah dulu menjadi teks sebelum diberikan ke LLM, atau diberikan langsung sebagai *soft prompt*. Kedua, LLM dapat disesuaikan dengan LoRA, atau cukup dibantu *adapter*. Ketiga, sinyal dapat diproses dengan atau tanpa RCT.

III.3.2 Analisis Penentuan Solusi

Penentuan solusi dilakukan dengan menyaring alternatif memakai tiga syarat wajib yang diturunkan dari kebutuhan, yaitu dapat dipakai tanpa operasi dan portabel (NF01), tidak bergantung pada otot (M03), dan menghasilkan keluaran berupa teks utuh (F06). Hasil penyaringan ditunjukkan pada Tabel III.4.

Tabel III.4 Penyaringan alternatif solusi

Alternatif	Tanpa operasi dan portabel	Tidak bergantung pada otot	Keluaran berupa teks utuh	Hasil
1. AAC	Terpenuhi	Tidak	Terpenuhi	Gugur
2. BCI invasif	Tidak	Terpenuhi	Tidak dinilai	Gugur
3. fMRI, MEG, fNIRS	Tidak (fNIRS portabel tetapi lambat)	Terpenuhi	Tidak dinilai	Gugur
4. EEG dan klasifikasi	Terpenuhi	Terpenuhi	Tidak	Tidak dipilih sebagai solusi, diper-tahankan sebagai pembanding
5. EEG, vektor makna, dan LLM	Terpenuhi	Terpenuhi	Terpenuhi	Dipilih

Alternatif 5 dipilih karena satu-satunya yang memenuhi ketiga syarat. Alternatif 4 tetap dipakai sebagai pembanding pada evaluasi (Hipotesis 2).

DAFTAR PUSTAKA

American Speech-Language-Hearing Association. (t.t.). *Aphasia*. ASHA Practice Portal. https://www.asha.org/practice-portal/clinical-topics/aphasia/

Barachant, A., Bonnet, S., Congedo, M., & Jutten, C. (2012). Multiclass brain–computer interface classification by Riemannian geometry. *IEEE Transactions on Biomedical Engineering*, *59*(4), 920–928. https://doi.org/10.1109/TBME.2011.2172210

Bleuzé, A., Mattout, J., & Congedo, M. (2022). Tangent space alignment: Transfer learning for brain–computer interface. *Frontiers in Human Neuroscience*, *16*, 1049985. https://doi.org/10.3389/fnhum.2022.1049985

Bricken, T., Templeton, A., Batson, J., Chen, B., Jermyn, A., dkk. (2023). Towards monosemanticity: Decomposing language models with dictionary learning. https://transformer-circuits.pub/2023/monosemantic-features/index.html

Britton, J. W., Frey, L. C., Hopp, J. L., Korb, P., Koubeissi, M. Z., Lievens, W. E., Pestana-Knight, E. M., & St. Louis, E. K. (2016). *Electroencephalography (EEG): An introductory text and atlas of normal and abnormal findings in adults, children, and infants*. American Epilepsy Society.

Cochrane, F., Siyambalapitiya, S., Nair, V., & Huang, A. (2025). Aphasia. Dalam G. L. Wallace (Penyunting), *Cultural sensitivity and responsiveness in neurorehabilitation: A personalized approach for speech-language pathologists* (pp. 261–284). Plural Publishing.

Cunningham, H., Ewart, A., Riggs, L., Huben, R., & Sharkey, L. (2023). Sparse autoencoders find highly interpretable features in language models. https://arxiv.org/abs/2309.08600

Duhair, H. T. M., Ibrahim, M. B. M., Farid, M., Alsayaydeh, J. A. J., & Herawan, S. G. (2026). EEG-based imagined-speech decoding: A review. *International Journal of Advanced Computer Science and Applications*, *17*(1). https://doi.org/10.14569/IJACSA.2026.0170136

Frey, J., Mühl, C., Lotte, F., & Hachet, M. (2014). Review of the use of electroencephalography as an evaluation method for human-computer interaction. *Proceedings of the International Conference on Physiological Computing Systems (PhyCS)*, 214–223. https://doi.org/10.5220/0004708102140223

He, H., & Wu, D. (2020). Transfer learning for brain–computer interfaces: A Euclidean space data alignment approach. *IEEE Transactions on Biomedical Engineering*, *67*(2), 399–410. https://doi.org/10.1109/TBME.2019.2913914

Higginbotham, D. J., Bisantz, A. M., Sunm, M., Adams, K., & Yik, F. (2009). The effect of context priming and task type on augmentative communication performance. *Augmentative and Alternative Communication*, *25*(1), 19–31. https://doi.org/10.1080/07434610802131869

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2021). LoRA: Low-rank adaptation of large language models. https://arxiv.org/abs/2106.09685

Jeong, J.-H., Cho, J.-H., Lee, Y.-E., Lee, S.-H., Shin, G.-H., Kweon, Y.-S., Millán, J. d. R., Müller, K.-R., & Lee, S.-W. (2022). 2020 international brain–computer interface competition: A review. *Frontiers in Human Neuroscience*, *16*, 898300. https://doi.org/10.3389/fnhum.2022.898300

Kementerian Kesehatan Republik Indonesia. (2018). *Laporan Nasional Riset Kesehatan Dasar (Riskesdas) 2018*. Badan Penelitian dan Pengembangan Kesehatan. Jakarta.

Lester, B., Al-Rfou, R., & Constant, N. (2021). The power of scale for parameter-efficient prompt tuning. *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, 3045–3059. https://doi.org/10.18653/v1/2021.emnlp-main.243

Li, X. L., & Liang, P. (2021). Prefix-tuning: Optimizing continuous prompts for generation. *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, 4582–4597. https://doi.org/10.18653/v1/2021.acl-long.353

López-Bernal, D., Balderas, D., Ponce, P., & Molina, A. (2022). A state-of-the-art review of EEG-based imagined speech decoding. *Frontiers in Human Neuroscience*, *16*, 867281. https://doi.org/10.3389/fnhum.2022.867281

Malmivuo, J., & Plonsey, R. (1995). *Bioelectromagnetism: Principles and applications of bioelectric and biomagnetic fields*. Oxford University Press.

Mokady, R., Hertz, A., & Bermano, A. H. (2021). ClipCap: CLIP prefix for image captioning. https://arxiv.org/abs/2111.09734

Nicolas-Alonso, L. F., & Gomez-Gil, J. (2012). Brain computer interfaces, a review. *Sensors*, *12*(2), 1211–1279. https://doi.org/10.3390/s120201211

Oppenheim, A. V., & Schafer, R. W. (2010). *Discrete-time signal processing* (3rd edisi). Pearson.

Pereira, F., Lou, B., Pritchett, B., Ritter, S., Gershman, S. J., Kanwisher, N., Botvinick, M., & Fedorenko, E. (2018). Toward a universal decoder of linguistic meaning from brain activation. *Nature Communications*, *9*(1), 963. https://doi.org/10.1038/s41467-018-03068-4

Rastogi, S., Dhanda, K., Bakshi, A., Kumar, T., & Bedi, J. (2026). From noisy neural time series to structured language: A foundation model for imagined speech decoding from EEG signals. *1st ICLR Workshop on Time Series in the Age of Large Models, ICLR 2026*. https://iclr.cc/virtual/2026/10013826

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 3982–3992. https://doi.org/10.18653/v1/D19-1410

Tang, J., LeBel, A., Jain, S., & Huth, A. G. (2023). Semantic reconstruction of continuous language from non-invasive brain recordings. *Nature Neuroscience*, *26*(5), 858–866. https://doi.org/10.1038/s41593-023-01304-9

Urigüen, J. A., & Garcia-Zapirain, B. (2015). EEG artifact removal—state-of-the-art and guidelines. *Journal of Neural Engineering*, *12*(3), 031001. https://doi.org/10.1088/1741-2560/12/3/031001

Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, *1*(6), 80–83. https://doi.org/10.2307/3001968

Wolpaw, J. R., Birbaumer, N., McFarland, D. J., Pfurtscheller, G., & Vaughan, T. M. (2002). Brain–computer interfaces for communication and control. *Clinical Neurophysiology*, *113*(6), 767–791. https://doi.org/10.1016/S1388-2457(02)00057-3

Wolpaw, J. R., & McFarland, D. J. (2004). Control of a two-dimensional movement signal by a noninvasive brain–computer interface in humans. *Proceedings of the National Academy of Sciences*, *101*(51), 17849–17854. https://doi.org/10.1073/pnas.0403504101

Zanini, P., Congedo, M., Jutten, C., Said, S., & Berthoumieu, Y. (2018). Transfer learning: A Riemannian geometry framework with applications to brain–computer interfaces. *IEEE Transactions on Biomedical Engineering*, *65*(5), 1107–1116. https://doi.org/10.1109/TBME.2017.2742541

Zhang, W., & Wu, D. (2020). Manifold embedded knowledge transfer for brain–computer interfaces. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, *28*(5), 1117–1127. https://doi.org/10.1109/TNSRE.2020.2985996

Zhao, W. X., Zhou, K., Li, J., Tang, T., Wang, X., dkk. (2023). A survey of large language models. https://arxiv.org/abs/2303.18223

Zhou, Y., Wu, J., Ren, Z., Yao, Z., Lu, W., Peng, K., Zheng, Q., Song, C., Ouyang, W., & Gou, C. (2025). CSBrain: A cross-scale spatiotemporal brain foundation model for EEG decoding. https://arxiv.org/abs/2506.23075

LAMPIRAN A

SOURCE CODE

A.1 Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik

Listing A.1 Binary search code

```
% -- Example of pseudocode and source code listing --
% -- Gunakan minipage agar listing tidak terpotong ke halaman
   berikutnya --



\begin{minipage}{\textwidth}
\begin{lstlisting}[caption={Iterative binary search in Python},
   label={lst:binary_iter}, frame=single, captionpos=t, language=
   Python]
def binary_search(arr, target):
    """
    Performs binary search on a sorted array.

    Args:
        arr: A sorted list of elements
        target: The element to search for

    Returns:
        Index of target if found, -1 otherwise
    """
    left = 0
    right = len(arr) - 1

    while left <= right:
        mid = (left + right) // 2

        if arr[mid] == target:
            return mid
        elif arr[mid] < target:
            left = mid + 1
        else:
```

```
            right = mid - 1

    return -1


\end{lstlisting}
\end{minipage}
```

A.2 Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak

asdjfkjashdkjfas